
ROBOTS MÓVILES

Trabajo teórico: Deep Learning en Robótica Móvil

Ingeniería Robótica (Universidad de Alicante)

15/01/2021

Aragonés Soriano, Carlos
Ellarby Sánchez, Nicolás
Rodríguez Quevedo, Ángel

ÍNDICE

	Págs
1. INTRODUCCIÓN	2
2. HISTORIA Y ANTECEDENTES	3
3. ESTADO DEL ARTE	5
4. TÉCNICAS A USAR	7
5. ÁREAS DE APLICACIÓN	13
6. EJEMPLOS DE APLICACIÓN	16
7. CONCLUSIONES	22
8. REFERENCIAS	23

1. INTRODUCCIÓN

Gracias al Machine Learning en estos últimos años, se pueden aplicar algoritmos que permiten identificar patrones complejos entre una cantidad muy grande de datos, de manera que a partir de estos patrones se puedan aplicar a nuevos conjuntos. De esta manera, se crean sistemas inteligentes que mejoran a partir de las muestras de datos dadas y pueden aprender a predecir comportamientos, detectar similitudes o encontrar anomalías de forma automática.

El Machine Learning se compone principalmente de tres métodos de aprendizaje: El aprendizaje Supervisado es aquel tipo de aprendizaje en el que se le muestra al algoritmo ejemplos de lo que se quiere conseguir. Se dispone de datos de entrada y datos de salida y el algoritmo encontrará la relación que existe entre ellos. Por antonomasia también existe el aprendizaje No Supervisado, al cual no se le muestra ningún ejemplo de salida de lo que se quiere conseguir y, aunque pueda parecer inútil, se puede extraer información muy relevante de la información de salida. Por último, también existe el aprendizaje por refuerzo que es aquel que permite a un agente inteligente aprender autónomamente un proceso a partir de unas recompensas dadas siguiendo una estrategia de resolución de un entorno determinado.

Una gran parte de la investigación que se está llevando a cabo hoy en día se está produciendo en la robótica móvil, ya que es un campo que puede aportar muchos beneficios en la sociedad actual. Los robots móviles representan un desafío, ya que deben ser completamente autónomos y por ello se requiere que se deben superar problemáticas tales como la incertidumbre en la detección, la planificación, el aprendizaje, la confiabilidad o la respuesta en tiempo real de manera autosuficiente.

En el presente trabajo se pretende profundizar en las diferentes técnicas para llevar a cabo todas estas tareas y de qué manera interactúan los diferentes procesos para llegar hasta donde hemos llegado.

2. HISTORIA Y ANTECEDENTES

En 1960 se construyó en el Instituto de Investigación de Stanford uno de los primeros robots móviles, Shakey. Shakey se hizo a partir de un sistema de planificación STRIPS, dos motores paso a paso, una cámara de televisión y un telémetro óptico. El sistema de planificación no era muy eficiente por lo que la investigación posterior se centró en un procesamiento más rápido y de mayor eficiencia.

En 1980, se empezó a cuestionar la visión de planificación clásica del diseño de agentes y robots inteligentes y comenzaron a trabajar en máquinas de estados finitos cuyas entradas están directamente vinculadas a las salidas. Esto se implementó en el robot Flakey y este ganó el segundo premio en la primera exhibición de robots de la Asociación Estadounidense de Inteligencia Artificial celebrada en 1992.

En 1986, Rodney Brooks publicó un artículo sobre la arquitectura de subsunción, un sistema de control de robots basado en máquinas de estados finitos, que condujo al desarrollo de un nuevo enfoque en robótica llamado robótica basada en el comportamiento.




Ilustración 1: El primer robot móvil, Shakey

En 1997, se crea la primera competición con el fin de promover la Inteligencia Artificial y la robótica. En este torneo, se crean robots móviles con el uso de la Inteligencia Artificial para jugar varios juegos como al fútbol. En 2002, se crea el Roomba, el primer robot para el hogar que limpia. Es capaz de detectar y evitar obstáculos a la vez que navegar sin el uso de mapas. En ese mismo año, el primer enjambre de robots colaborativos de robots móviles se usa para inspeccionar un área y construir un mapa en tiempo real sin supervisión humana.



Ilustración 2: Primer robot de limpieza, el Roomba

Dos años más tarde, en 2004, el primer robot se manda a Marte (Mars Robot). Este robot sobrepasó las expectativas de tiempo de vida ya que consiguió navegar por Marte, completando tareas durante años (en vez de los 90 días que se esperaba). Un año más tarde la universidad de Stanford ganó el desafío de vehículos autónomos, consiguieron que el coche condujese de forma autónoma a través de un terreno desértico de 175 millas de largo sin intervención humana.




Ilustración 3: El primer robot mandado a Marte, Mars Robot

Hoy en día la Inteligencia Artificial está muy presente en la robótica móvil. Es un campo de la investigación que está constantemente creciendo y se está investigando mucho; desde los coches autónomos de grandes empresas, a robots móviles para la exploración espacial o para la realización de tareas en lugares

peligrosos hasta solamente investigar y mejorar técnicas de navegación, mapeado y evitación de obstáculos a partir de la IA.



Ilustración 4: Coche autónomo de Google (izquierda) y un Robot Militar (derecha).

3. ESTADO DEL ARTE

Las posibilidades del aprendizaje automático se han multiplicado gracias a la tecnología deep learning. Por ejemplo, los nuevos procesadores son capaces de realizar cálculos complicados o la tecnología big data conectada con las técnicas deep learning permiten programar las máquinas para hacer lecturas inteligentes. En este momento, el deep learning es una tecnología que consigue muy buenos resultados ya que agrupa información y la procesa de manera inteligente, pero sigue en desarrollo y aunque destaca por sus aplicaciones fuera del campo de la robótica móvil, muchas de estas se podrían aplicar fácilmente a dicha área. No obstante, hay una infinidad de desarrollos en el presente, cuyo campo más en expansión es el de los vehículos autónomos y el mapping, la navegación autónoma y la localización.

En este campo, la inteligencia artificial (tanto machine learning como deep learning que es una parte del anterior) y el vehículo tienen que ir unidos ya que la autonomía del vehículo no se puede conseguir sin esta adhesión. Al disponer de múltiples dispositivos eléctricos como GPS o cámaras, los coches autónomos captan el comportamiento de diversas variables del entorno, como la presencia o la forma de obstáculos de la vía. Esta información es almacenada continuamente en bases de datos internas del ordenador del automóvil. Los algoritmos de aprendizaje profundo y automático permiten establecer modelos matemáticos que caracterizan la relación de las variables externas. Con estos modelos, el ordenador es capaz de emitir señales que ponen en funcionamiento distintos dispositivos como válvulas o motores mecánicos y/o eléctricos de los coches autónomos, conocidos como actuadores, posibilitando el control automático de variables de conducción, como la velocidad, fuerza de frenado o posicionamiento de giro de los neumáticos del coche, entre otras.

Por otra parte, los algoritmos se modifican a sí mismos, permitiendo mejorar los modelos de comportamiento, por lo cual a mayor cantidad de horas de funcionamiento, mayor será la autonomía de conducción del coche. En conclusión, no es posible la conducción autónoma sin la IA.



Ilustración 5: NVIDIA BB8, coche autónomo que usa algoritmos de deep learning.

Pese a los numerosos desarrollos que se pueden realizar en este campo, hay muchas investigaciones que se completarán en un futuro y que supondrán un gran avance tecnológico tanto para la robótica móvil como para los algoritmos de deep learning; y, por supuesto, con la combinación de ambos.

Además, estas investigaciones tienen muchos retos, entre los que se destaca, a muy largo plazo, el desafío de trasladar los principios fundamentales de los seres vivos a las reglas de diseño en ingeniería o integrar componentes vivos en estructuras sintéticas para crear robots que funcionen como sistemas naturales. Otros retos son:

- **Los enjambres de robots:** permitirán crear unidades modulares más simples y menos costosas que se reconfiguren en un equipo, según la tarea que se deba realizar, al tiempo que serán tan efectivas como un robot más grande y específico para cada tarea.
- **La navegación y exploración en ambientes extremos:** creación de máquinas capaces de navegar y explorar en entornos extremos apenas conocidos, como las profundidades marinas. En esos ambientes hostiles será crucial que los robots tengan la habilidad para adaptarse o recuperarse de los fallos.
- **La propia inteligencia artificial:** se tendrá que mejorar en el propio aprendizaje, así como el reconocimiento avanzado de patrones y el

razonamiento basado en modelos, además de tratar de concebir inteligencia con sentido común.

Se están realizando nuevas investigaciones y se está en proceso de realizar retos a largo plazo, también se está empezando a explorar nuevos métodos de aprendizaje como pueden ser:

- **Aprendizaje basado en casos:** las experiencias se almacenan y estructuran como una estructura de caso, luego se recuperan y se adaptan según sea necesario en función de la situación actual.
- **Aprendizaje basado en la memoria:** se utilizan muchos registros individuales de experiencias pasadas para derivar aproximadores de funciones para las leyes de control. Las funciones de control complejas se aproximan mediante la interpolación de experiencias exitosas pasadas relacionadas entre sí.
- **Aprendizaje basado en explicación:** utiliza modelos simbólicos del dominio para guiar la generalización y especialización de un concepto por inducción. El aprendizaje ocurre instancia por instancia, y el refinamiento del modelo subyacente ocurre en todos los pasos del proceso. El conocimiento específico del dominio es crucial para que este proceso funcione de manera eficaz.

4. TÉCNICAS A USAR

Primeramente, antes de comenzar a explicar las diferentes técnicas existentes, se han de conocer los diferentes enfoques de aprendizaje de robots:

- **Aprendizaje de funciones numéricas para calibración o ajuste de parámetros:** optimiza los parámetros operativos en una estructura de comportamiento existente. En muchos casos, los parámetros de un robot no se pueden predecir y se han de elegir o calcular en tiempo de ejecución. El aprendizaje de funciones es la forma más débil de aprendizaje, ya que la estructura de los programas que producen el comportamiento están predeterminados y no cambian según la experiencia. En lugar de introducir nuevos conocimientos, afina los conocimientos existentes. Además, este enfoque ha sido el más exitoso actualmente.
- **Aprendiendo sobre el mundo:** crea y altera alguna representación del mundo. La información suele estar representada de forma simbólica y abstracta. Aprender sobre el mundo puede variar de aprender mapas del entorno para conocer conceptos abstractos.

- **Aprender a coordinar comportamientos:** intenta resolver la selección de acciones, es decir, trata de determinar cuándo se deben ejecutar acciones o comportamientos particulares. Los métodos de aprendizaje por refuerzo son adecuados para este tipo de aprendizaje, ya que producen el tipo de mapeo entre condiciones y acciones necesarias para decidir cómo comportarse en cada punto distinto en el espacio de estados.
- **Aprender nuevos comportamientos:** construye nuevas estructuras de comportamiento. Se han utilizado técnicas de aprendizaje por refuerzo para aprender nuevos comportamientos, pero sólo en el sentido de que los comportamientos se construyen a partir de secuencias arbitrarias. Un enfoque completamente diferente para aprender comportamientos que tiene alguna promesa es el uso de programación genética. Este tipo de aprendizaje se ha probado en simulación y para crear comportamientos simples en robots reales.

Una vez presentadas las técnicas utilizadas, existen varios métodos que se pueden implementar usando deep learning en el campo de la robótica móvil en concreto. Se destacan las siguientes:

- **Redes multicapa de perceptrón:** red neuronal artificial (RNA) formada por múltiples capas, de tal manera que tiene capacidad para resolver problemas que no son linealmente separables, lo cual es la principal limitación del perceptrón (también llamado perceptrón simple) por lo que el perceptrón multicapa evoluciona el perceptrón simple incorporando capas de neuronas ocultas.

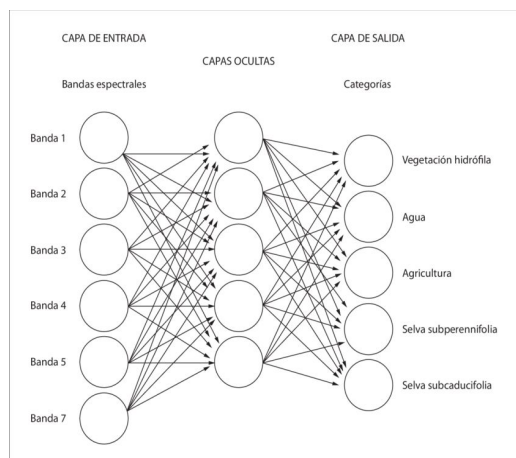


Ilustración 6: Esquema de una red multicapa de perceptrón.

El perceptrón multicapa está compuesto por una capa de entrada, una de salida y n-capas ocultas intermedias. Estas capas se caracterizan por tener salidas diferentes pero relacionadas entre sí por lo que la salida de una neurona será la entrada de la siguiente.

Se pueden diferenciar distintas fases en el perceptrón multicapa:

1. Propagación en la que se calcula el resultado de salida de la red desde los valores de entrada hacia delante.
2. Aprendizaje en el que los errores obtenidos a la salida del perceptrón se van propagando hacia atrás (*backpropagation*) con el objetivo de modificar los pesos de las conexiones para que el valor estimado de la red se asemeje cada vez más al real. Esta aproximación se realiza mediante la función gradiente del error, que también se conoce como retropropagación del error o regla delta generalizada. Debido a que es usado en el entrenamiento de este tipo de redes, se le conoce al perceptrón multicapa, también, como red de retropropagación.

Esta técnica tiene una propiedad característica: las funciones de transferencia de las neuronas han de ser derivables. Sin embargo, tiene una serie de limitaciones:

- Si la red entrena de forma incorrecta o insuficiente, las salidas pueden ser imprecisas.
- La existencia de mínimos locales en la función de error dificulta considerablemente el entrenamiento, pues una vez alcanzado un mínimo, el entrenamiento se detiene aunque no se haya alcanzado la tasa de convergencia fijada.

Esta técnica se puede usar en varias aplicaciones:

- Aprendizaje a través de retropropagación.
 - Compresión y descompresión de datos.
 - Reconocimiento de números: reconocer un número de una imagen.
- **Redes neuronales convolucionales:** esta técnica es muy parecida a la anterior pero su principal ventaja es que cada parte de la red se entrena para realizar una tarea, reduciendo significativamente el número de capas ocultas y haciendo un entrenamiento más rápido. También, presenta invarianza a la traslación de los patrones a identificar.

Su arquitectura la forman una serie de capas convolucionales y de reducción alternadas que constituyen la fase de extracción de características y finalmente unas capas de conexión total que se encargan de realizar la clasificación final sobre las características extraídas.

En la fase de extracción de características, mientras se procesan los datos, se reduce su dimensionalidad, siendo las neuronas en capas lejanas mucho menos sensibles a perturbaciones en los datos de entrada, pero al mismo tiempo siendo estas activadas por características cada vez más complejas.

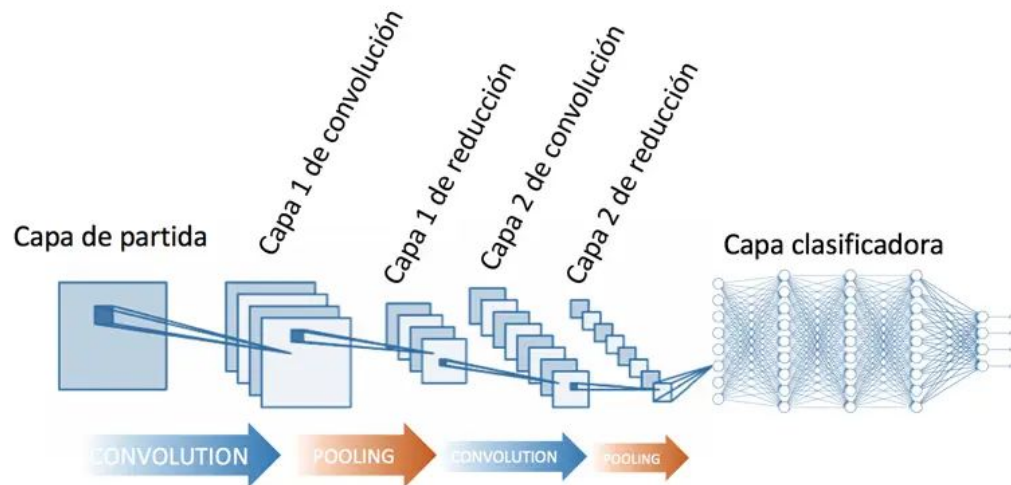


Ilustración 7: Esquema de una red neuronal convolucional.

Por tanto se disponen de tres tipos de neuronas distintas:

- Neuronas convolucionales: se realizan productos y sumas entre la capa de partida y los n filtros (o kernel) que genera un mapa de características. Las características extraídas corresponden a cada posible ubicación del filtro en la imagen original.

Para su implementación se sigue la siguiente fórmula en la que la salida Y_j de la neurona j es una matriz que se calcula mediante la combinación lineal de las salidas Y_i de las neuronas en la capa anterior cada una de ellas operadas con el núcleo de convolucional K_{ij} correspondiente a esa conexión. Esto se suma a una influencia b_j y luego se pasa por una función de activación $g(\cdot)$ no lineal. La función de activación recomendada es la sigmoide ReLU, seleccionando una tasa de aprendizaje adecuada y monitorizando la fracción de neuronas muertas, también se podría probar con Leaky ReLU o Maxout, pero nunca utilizar la sigmoide logística.

$$Y_j = g(b_j + \sum_i K_{ij} \otimes Y_i)$$

Se usa el mismo filtro para extraer la misma característica en cualquier parte de la entrada, consiguiendo reducir el número de conexiones y el número de parámetros a entrenar en comparación con una red multicapa de conexión total.

- Neuronas de reducción de muestreo (*pooling*): el objetivo es disminuir la cantidad de parámetros al quedarse con las características más comunes.

La forma de reducir parámetros se realiza mediante la extracción de estadísticas como el promedio o el máximo de una región fija del mapa de características. Al reducir características el método pierde precisión aunque mejora su compatibilidad.

Esta forma se puede implementar con un proceso de subsampling que era cómo se hacía originalmente. No obstante, hay otras operaciones que son más eficaces como max-pooling que encuentra el valor máximo entre una ventana de muestra y pasa este valor como resumen de características sobre esa área, reduciendo el tamaño de los datos por un factor igual al tamaño de la ventana de muestra sobre la que se opera.

- Neuronas de clasificación: capas completamente conectadas en la que cada píxel se considera como una neurona separada. Esta capa clasificadora tendrá tantas neuronas como el número de clases a predecir.

La salida de cada neurona se calcula con la siguiente fórmula, la cual es similar a la previamente usada en las neuronas convolucionales, con la diferencia que en lugar de hacer la convolución presentada anteriormente, se realiza una suma entre la salida y_i de las neuronas de la capa anterior con un peso w_{ij} correspondiente a esa conexión.

$$y_j = g(b_j + \sum_i w_{ij} + y_i)$$

Algunas aplicaciones pueden ser:

- Análisis de imágenes: esta técnica es capaz de detectar características simples (bordes, líneas...) y componer características más complejas hasta obtener lo que se busca.

- Clasificación de series de tiempo o señales de audio.
- Clasificaciones de datos volumétricos.
- **Redes neuronales recurrentes de larga duración y corta memoria:** no tiene una estructura de capas definida, sino que permiten conexiones arbitrarias entre las neuronas, incluso pudiendo crear ciclos, con esto se consigue crear la temporalidad, permitiendo que la red tenga memoria.




Ilustración 8: Esquema de una red neuronal recurrente de larga duración y corta memoria.

Guarda una serie de ventajas respecto a la red neuronal clásica:

- Tratamiento de datos secuenciales de forma eficiente.
- Recuerdan las salidas anteriores como entrada.
- Pueden tratar secuencias muy largas, elemento a elemento.

El campo de uso más destacado de este tipo de técnica es el de análisis de secuencias:

- Análisis de textos.
- Análisis de vídeo.
- Análisis de sonido.

Hay varios tipos de redes neuronales recurrentes de larga duración y corta memoria, de los que destacan:

- Redes recurrentes simples (SRN o Elman): arquitectura base sobre la que se implementan el resto. Son utilizadas para problemas como reconocimiento de la voz o reconocimiento de la escritura a mano.
- Redes LSTM: tipo especial de red neuronal recurrente que solventa el problema de la aparición de desvanecimiento de gradiente (*vanishing gradient*) debido a que cuanto más larga sea la secuencia temporal a analizar, mayor será el número de capas a desenrollar. Esto se soluciona incorporando capas de tipo LSTM que permiten el

backpropagation through time conectando eventos que aparecen muy alejados en los datos de entrada, sin que su peso se diluya entre las capas.

Las redes LSTM se utilizan para compresión de textos de lenguajes naturales, reconocimiento de escritura a mano, reconocimiento de voz, reconocimiento de gestos, captura de imágenes...

- Redes GRU: tipo especial de red neuronal recurrente que solventa el mismo problema que las redes LSTM y son más simples que este tipo debido a:
 - Tienen menos parámetros.
 - Carecen de puerta de salida.
 - Capacitan de una forma más rápida.
 - Más eficientes en su ejecución.

Presentan un mejor rendimiento en conjuntos de datos más pequeños. En contraposición, las redes LSTM al operar con conjuntos de datos más amplios, pueden ser más expresivas y proporcionar mejores resultados ante contextos complejos.

5. ÁREAS DE APLICACIÓN

Las redes neuronales se han utilizado en una variedad de tareas, incluyendo visión por computador, reconocimiento de voz, traducción automática, filtrado de redes sociales, juegos de mesa, videojuegos y diagnóstico médico. Dentro de la robótica móvil, se encuentran una serie de tareas que se pueden llevar a cabo mediante el uso de deep learning con un robot mientras se mueve:

- **Reconocimiento automático del habla:** las RNNs de LSTM pueden aprender tareas de “aprendizaje muy profundo” que implican intervalos de varios segundos con eventos de voz separados por miles de pasos de tiempo discretos, donde un paso de tiempo corresponde a unos 10 ms. Hay varios ejemplos de reconocedores de voz que se pueden integrar en un robot móvil de tal forma que reconozca la voz mientras se completa una determinada acción.

- **Reconocimiento de imagen:** el reconocimiento de imágenes basado en el aprendizaje profundo se ha convertido en “sobrehumano”, produciendo resultados más precisos que los propios humanos. Algunos ejemplos pueden ser los vehículos entrenados para el aprendizaje profundo que interpretan vistas de cámara de 360° o el Novedoso Análisis de Dismorfología Facial (FDNA) que se utiliza para analizar casos de malformaciones humanas.
- **Procesamiento de artes visuales:** muy relacionado con la anterior aplicación. Los DNNs han demostrado ser capaces de identificar el período de estilo de una pintura dada, “capturar” el estilo de una pintura dada y aplicarlo de una manera visualmente agradable a una fotografía arbitraria y de generar imágenes llamativas basadas en campos visuales aleatorios.
- **Procesamiento del lenguaje natural:** las redes neuronales se han utilizado para implementar modelos de lenguaje desde principios de la década de 2000. LSTM ayudó a mejorar la traducción automática y el modelado de idiomas.

Otras técnicas clave en este campo son el muestreo negativo y la inserción de palabras. La incrustación de palabras puede considerarse como una capa de representación en una arquitectura de aprendizaje profundo que transforma una palabra atómica en una representación posicional de la palabra en relación con otras palabras del conjunto de datos; la posición se representa como un punto en un espacio vectorial. El uso de la incrustación de palabras como una capa de entrada de RNN permite que la red analice frases y frases utilizando una gramática vectorial de composición efectiva.

- **Fiabilidad de los sistemas de infraestructura:** es crucial optimizar las decisiones relativas a las prácticas de mitigación, preparación, respuesta y recuperación para estos sistemas. Esto requiere medios precisos y eficientes para evaluar la fiabilidad del sistema de infraestructura. Las redes neuronales profundas han sido utilizadas para el análisis preciso, eficiente y acelerado de la confiabilidad del sistema de infraestructura. Todo ello, se puede adaptar a un robot móvil para que evalúe la fiabilidad de la infraestructura deseada.
- **Restauración de imágenes:** el aprendizaje profundo se ha aplicado con éxito a problemas inversos como la eliminación de ruido, la superresolución y la pintura interior. Estas aplicaciones incluyen métodos de aprendizaje tales como “Campos de Contracción para la Restauración Efectiva de Imágenes” que se entrena en un conjunto de datos de imágenes, y Deep Image Prior, que se entrena en la imagen que necesita restauración.

- **Otros:** no son aplicaciones tan destacadas del deep learning sobre robots móviles (sí lo son en cuanto al deep learning únicamente) aunque se podría implementar en un futuro de forma conjunta:
 - Descubrimiento de fármacos y toxicología: la investigación ha explorado el uso del aprendizaje profundo para predecir el objetivo biomolecular, los efectos tóxicos y fuera de objetivo de los productos químicos ambientales en los nutrientes, los productos domésticos y los medicamentos. Un ejemplo de este éxito es AtomNet que es un sistema de aprendizaje profundo para el diseño racional de medicamentos basado en estructuras.
 - Gestión de la relación con el cliente: tiene como objetivo aproximar el valor de posibles acciones de marketing directo, definidas en términos de variables RFM.
 - Sistemas de recomendación: su misión es la de extraer características significativas para un modelo de factores latentes para las recomendaciones musicales basadas en el contenido. Se ha aplicado el aprendizaje profundo Multiview para aprender las preferencias del usuario desde múltiples dominios. El modelo utiliza un enfoque híbrido de colaboración y basado en el contenido y mejora las recomendaciones en múltiples tareas. Podría llevarlo implementado un coche autónomo con un sistema de audio inteligente que use este sistema de recomendación.
 - Bioinformática: el aprendizaje profundo se utilizó para predecir la calidad del sueño basándose en los datos y las predicciones de complicaciones de salud a partir de los datos de la historia clínica electrónica. El aprendizaje profundo también ha mostrado eficacia en el cuidado de la salud. Podría emplearse en un robot móvil enfermero.

En adición, otro campo de aplicación más extendido es el del mapping en robots móviles. En esta área se pueden usar múltiples descriptores, de los cuáles se destacan aquellos basados en deep learning. Estos descriptores se obtienen de una capa intermedia incluida en una red neuronal convolucional (CNN). Estas redes reciben un exhaustivo entrenamiento para llevar a cabo una determinada tarea. Las CNNs están compuestas por varias capas ocultas, cuyos parámetros y ponderaciones se ajustan durante el proceso de entrenamiento. La idea consiste en introducir a la CNN la imagen y extraer un vector de una de las capas intermedias, de manera que ese vector sea el descriptor de apariencia global.

Este descriptor se usaría para que el robot se mueva a través del entorno y por ejemplo; capture imágenes omnidireccionales, calculando el descriptor de apariencia global para cada imagen capturada con el objetivo de, tras recorrer el entorno, obtener un dataset visual formado por todos los descriptores calculados, correspondiendo cada descriptor a una imagen.

6. EJEMPLOS DE APLICACIÓN

- **MiR1000:**

En 2019, la empresa pionera y referente en robótica colaborativa **Mobile Industrial Robots (MiR)** lanza el primer robot móvil del mundo con Inteligencia Artificial para intralogística, el MiR1000. Este robot es capaz de recoger, transportar y entregar automáticamente paletas y otras cargas pesadas de hasta 1000 kg a través de entornos dinámicos. Se construyó como una alternativa colaborativa, segura y flexible a las potencialmente peligrosas y costosas carretillas en la planta de producción.



Ilustración 9: El último robot de Mobile Robot Industrial MiR1000.

Se trata del primer robot móvil del mundo con Inteligencia Artificial (IA) que consigue llevar la navegación robótica a un nuevo nivel. Para mejorar la navegación se han lanzado las primeras capacidades de IA de la industria al servicio de la intralogística, que permite mejorar la navegación y la capacidad de distinguir entre humanos, carretillas elevadoras y otros obstáculos y reaccionar con mayor eficiencia en la logística interna. Las capacidades de IA incorporadas en el software y cámaras estratégicamente ubicadas funcionan como un conjunto extendido de sensores robóticos. De esta forma se consigue optimizar la planificación de rutas y el comportamiento de conducción en las líneas de la intralogística. Por ejemplo, los robots seguirán conduciendo como de costumbre y si detectan a una persona se pararán para

seguir a continuación su ruta. Sin embargo, si detectan un vehículo guiado autónomo tradicional le ceden el paso para que este pueda pasar. El robot también puede predecir de antemano las zonas bloqueadas o con mucho tráfico y redirigir la ruta en lugar de entrar en la zona bloqueada y desviarla.

Este robot móvil se puede programar a través de la interfaz de usuario o a través del sistema de gestión de flotas de robots MirFleet, lo que facilita la automatización de nuevas tareas para toda la flota de robots de una empresa, según sea necesario. También, pueden integrar fácilmente diferentes módulos superiores como elevadores de palets, transportadores, un brazo robótico u otras opciones para soportar una amplia gama de aplicaciones.

- **Coche Autónomo Toyota:**

Durante los últimos años muchas empresas automovilísticas han dado un gran paso para conseguir el primer coche completamente autónomo. Ya existen varios vehículos con una gran capacidad de autonomía y también hay coches casi o completamente autónomos (como puede ser el de Google). Aún así, siempre hay problemas o mejoras que realizar para poder conseguir un vehículo 100% autónomo y seguro.



Ilustración 10: Coche Autónomo de Toyota.

Una de las empresas que está en la carrera de conseguir estos vehículos es el coche autónomo de Toyota. Este coche incluye como parte de su plataforma 3.0 un sistema LiDAR innovador por su rango de alcance, siendo capaz de detectar objetos situados en un radio de 200 metros. Esta es

otra de sus características, puesto que su complejo sistema ofrece una visión de 360 grados. El conjunto puede detectar objetos con una precisión mucho mayor que la mayoría de modelos de la competencia, incluyendo aquellos que cuentan con una mala visibilidad en condiciones de luminosidad pobres.

El coche funciona de la siguiente manera: el conductor establece un destino y el software del automóvil calcula una ruta y pone en marcha el automóvil. Un sensor LiDAR giratorio montado en el techo monitorea un rango de 200 metros alrededor del automóvil y crea un mapa dinámico en 3D del entorno actual del automóvil. Un sensor en la rueda trasera izquierda monitorea el movimiento lateral para detectar la posición del automóvil en relación con el mapa 3D. Los sistemas de radar en los parachoques delantero y trasero calculan las distancias a los obstáculos. El software de inteligencia artificial en el automóvil está conectado a todos los sensores y tiene entrada de Google Street View y cámaras de video. La IA simula los procesos de toma de decisiones y la percepción humana y controla los sistemas de conducción como la dirección y los frenos. El software del automóvil consulta a Google Maps para obtener un aviso previo de cosas como puntos de referencia, señales de tráfico y luces. Una función de anulación está disponible para permitir que una persona tome el control del vehículo. Los vehículos individuales pueden beneficiarse de la información obtenida de otros vehículos en las cercanías, especialmente la información relacionada con la congestión del tráfico y los peligros de seguridad. Los sistemas de comunicación vehicular utilizan vehículos y unidades de carretera como nodos de comunicación en una red de igual a igual, de esta forma, se proporcionan información entre sí.

Un ejecutivo del Instituto de Investigación de Toyota (TRI) comentó que la Inteligencia Artificial maneja las diversas partes del vehículo autónomo. Estas tres partes empiezan con la percepción que luego pasa a la predicción y finalmente a la planificación. El más problemático de estos tres es la fase de predicción ya que si el vehículo tuviese que predecir lo que va a hacer otro vehículo autónomo el problema sería mucho más simple pero lo que en verdad tiene que predecir es el comportamiento humano. Ahí está la complejidad de aprender para el deep learning en este momento. Con el deep learning existe la promesa de que si se arroja suficiente datos a las redes, finalmente funcionará. Pero resulta que la cantidad de datos que se necesita para los vehículos autónomos es mucho mayor de lo que se esperaba.

La forma de pensar sobre el deep learning es que se trata de una coincidencia de patrones de alto rendimiento. Tiene entrada y salida como pares de entrenamiento; se dice que una imagen debe conducir a un resultado y esto se hace cientos de miles, millones de veces.

Ahí está el error de mucha gente con el deep learning. Mucho de lo que se hace con nuestro cerebro se considera como una coincidencia de patrones: "Oh, veo esta señal de alto, así que debería detenerme". Pero no significa que toda la inteligencia se pueda realizar mediante la coincidencia de patrones. Por ejemplo, cuando una persona va conduciendo y ve a una madre sosteniendo la mano de un niño en una esquina y tratando de cruzar la calle, está bastante segura de que no va a cruzar en un semáforo en rojo y cruzar imprudentemente. Por experiencia como ser humano, se sabe que las madres y los niños no actúan de esa manera. Por otro lado, si hay dos adolescentes en patines, ¿Van a cruzar imprudentemente? Cuando una persona ve eso, instantáneamente en su mente va a pensar que la probabilidad de que crucen los adolescentes imprudentemente es mucho más alta que para la madre sosteniendo la mano del niño. No es que se hayan visto 100000 casos de niños pequeños, es que se entiende lo que es ser un adolescente o una madre sosteniendo la mano de un niño. Este tipo de inteligencia se puede intentar fingir. Si se consigue entrenar una red neuronal específicamente con datos como ese, se podría hacer coincidir ese patrón. La complejidad está en saber cómo hacerlo.

Un ejemplo de software de inteligencia artificial en el automóvil es ALVINN. ALVINN (*Autonomous Land Vehicle In a Neural Network*), es un sistema que utiliza redes neuronales para la navegación autónoma de robots. La arquitectura de red básica es una red neuronal de alimentación directa de una sola capa oculta, con 960 neuronas de entrada, 4 neuronas de capa oculta y 30 neuronas de salida. La capa de salida es una representación lineal de la dirección apropiada que puede servir para mantener el vehículo en la carretera o para evitar que choque con obstáculos cercanos. La unidad de salida más central representa la condición de "viaje en línea recta", mientras que las unidades a la izquierda y derecha del centro representan giros más pronunciados a izquierda y derecha. ALVINN se entrena utilizando el algoritmo de retropropagación con imágenes de una cámara montada en un vehículo en conducción.

- **Robótica de Limpieza**

A lo largo de la última década, se han producido mejoras drásticas en las capacidades de los robots de limpieza. De hecho, este tipo de productos ya se encuentran de pleno en su sexta generación, y, en estas últimas generaciones, se han aplicado tecnologías de Inteligencia Artificial, especialmente a los robots aspiradora. A continuación, se detallarán los principales modelos a los que se han aplicado estas tecnologías.

- iRobot Roomba

El primer producto que introdujo en el mercado esta empresa incorporaba realmente pocos elementos de Inteligencia Artificial en su sistema. Únicamente detectaba paredes y esquivaba elementos estáticos como sillas y mesas gracias a sus sensores incorporados. El último modelo de esta marca, el modelo 980, ya incorpora algoritmos de decisión movidos por Inteligencia Artificial. Ahora, el robot ya es capaz de escanear el tamaño de la habitación, identificar obstáculos y recordar las rutas y métodos más eficientes.



Ilustración 11: Primer modelo Roomba (izquierda) junto al modelo actual (derecha).

- Sharp RX-V100

Este robot de limpieza tiene incorporado un algoritmo de reconocimiento de voz mediante Inteligencia Artificial que permite al usuario interactuar con el robot para darle órdenes o para que este

dé información al usuario acerca del estado de la batería y del robot en general. Por ejemplo, cuando estando cerca del robot, se le ordena al robot limpiar mediante la instrucción “Limpia”, el robot contestará “De acuerdo” y el robot entrará en su modo automático y se pondrá a limpiar. También, es capaz de mantener una conversación con el usuario a partir de frases simples incorporadas en su algoritmo.



Ilustración 12: Sharp RX V-100.

- Bosch Roxxter

Es un tipo de robot aspirador que también incorpora Inteligencia artificial para crear mapas interactivos del entorno para que el usuario desde cualquier dispositivo móvil pueda asignarle instrucciones. Este modelo también es capaz de ser movido a través de mensajes de voz a partir de un dispositivo compatible con instrucciones como puede ser Alexa. Por ejemplo, se le pueden dar órdenes al robot mediante la instrucción “Alexa, envía al Home Connect al salón”.



Ilustración 13: Bosch Roxxter.

7. CONCLUSIONES

Actualmente, la robótica móvil se encuentra en pleno auge. Gracias a estas nuevas tecnologías y algoritmos implementados, se están consiguiendo resultados fiables que posibilitan que estos dispositivos funcionen autónomamente y de forma segura, siendo este último un aspecto indispensable para este sector, ya que al tratarse de robots que se mueven en un entorno determinado, se encontrarán habitualmente en situaciones en las que se tengan que enfrentar a elementos dinámicos que no constan en su mapa inicial. Es crucial que estos sistemas sean realmente eficientes, ya que de lo contrario se podrían producir accidentes realmente graves.

Para que estos robots puedan ser totalmente fiables, se tienen que tener en cuenta diversos aspectos y tratarlos separadamente. Entre estos aspectos se encuentra la localización, el cálculo de rutas o la evitación de obstáculos, entre otros. Como ya se ha comentado, resulta indispensable que el robot sea capaz de interpretar realmente bien los cambios que se producen en el entorno.

Todo este tipo de procedimientos a automatizar, es posible gracias a los nuevos elementos que se han incorporado en estos últimos años. Desde las primeras aplicaciones autónomas militares hasta la fecha actual, se han realizado mejoras en todos los campos, siendo de especial importancia la fiabilidad y seguridad conseguidas mediante las nuevas técnicas de Inteligencia y Visión artificial que se han mejorado durante estos últimos años.

En el futuro, todos estos aspectos se van a mejorar tanto que los robots móviles serán completamente autónomos, de manera que los humanos y los robots serán capaces de interactuar de una forma continua y sin ningún tipo de riesgo.

También es importante destacar el papel indispensable del internet de las cosas (IoT), ya que gracias a este concepto todos los robots móviles serán capaces de comunicarse con su entorno (tanto con personas como con otros sistemas autónomos) para que de esta manera conseguir una colaboración completa entre el humano y las máquinas.

Cabe mencionar que se ha realizado un vídeo con la presentación del trabajo teórico que se encuentra en el siguiente enlace:

https://drive.google.com/file/d/1AVoeOJEQKuVG-WWOuK1_ICO4YMLnkjx3/view?usp=sharing

8. REFERENCIAS

- <https://www.iic.uam.es/inteligencia-artificial/machine-learning-deep-learning/>
- <https://www.nuevamovilidad.com/vehiculos-autonomos/la-inteligencia-artificial-en-los-coches-autonomos/>
- <https://www.muyinteresante.es/tecnologia/fotos/los-mayores-retos-de-los-robots-de-cara-al-futuro/4>
- <https://www.universia.net/mx/actualidad/actualidad.vida-universitaria.tecnicas-deeplearning-problema-o-solucion-1162620.html>
- https://es.wikipedia.org/wiki/Perceptr%C3%B3n_multicapa
- <https://www.diegocalvo.es/perceptron-multicapa/>
- <https://unipython.com/deep-learning-aprendizaje-profundo/#:~:text=El%20aprendizaje%20profundo%20es%20una,la%20capa%20anterior%20como%20entrada.>
- https://es.wikipedia.org/wiki/Redes_neuronales_convolucionales
- <https://www.diegocalvo.es/red-neuronal-convolucional/>
- <https://www.diegocalvo.es/red-neuronal-recurrente/>
- https://es.wikipedia.org/wiki/Red_neuronal_recurrente
- <https://hipertextual.com/2018/01/nuevo-coche-autonomo-toyota-con-vision-360o-hasta-200-metros-alcance>
- https://ruc.udc.es/dspace/bitstream/handle/2183/23739/2019_Cebollada-Sergio_Uso-tecnicas-machine-learning-mapping-robotica.movil.pdf
- <https://emerj.com/ai-sector-overviews/artificial-intelligence-home-robots-current-future-use-cases/>
- https://www.researchgate.net/publication/2379199_The_use_of_Artificial_Intelligence_in_autonomous_mobile_robots/link/573ec87c08ae298602e8b278/download

